

졸업논문

식약처 허가원문 기반 국내 일반의약품 안전성 조회 시스템과 AI 자율 문헌 근거층 구축

v4.0 최종 보고

연세대학교 약학대학
2021194024 권혁찬
2026년 7월

초록

성능 수치의 기준 이 논문의 민감도·특이도·정밀도·F1은 모두 AI 참조표준 대비 값이다. 사람 참조표준이 아니며 절대적 진실 대비 정확도가 아니다. 사람 판정은 0건이다.

이 연구는 국내 일반의약품의 제품명으로 입력하면 중복 성분, 최대용량, 복용 간격, 연령, 질환, 병용약 위험 신호를 허가원문과 함께 보여 주는 조회 시스템을 다룬다. 결정론적 허가원문 층에는 분석 제품 13개, 고유 성분 28개, 제품-성분 연결 47개, 복용 조건 32개가 포함된다. 규칙은 전체 16개이고 그중 15개가 source 와 locator를 갖춘 released 상태다. 문헌은 이 판정을 대신하지 않고 위해 연관성을 설명하는 별도 참고 근거층으로 설계했다.

AI는 허가원문에서 확인한 성분과 규칙 범위만 입력받아 PICOS 질문 5개를 만들고 PubMed를 검색했다. 질문별 hit 합계는 5,742건이었고 중복 제거 뒤 고유 PMID 5,724개를 확보했다. 초록 보유 문헌은 5,424개, 제목만 있는 문헌은 300개였다. 코퍼스 전체 5,724행을 선별해 커버리지 1.0을 달성했으며 retain 2,240건, deprioritize 3,423건, uncertain 61건이었다.

선별기의 재현도는 증화 표본 300건에 대한 독립 AI 참조표준으로 측정했다. AI 참조표준 대비 민감도 0.8482, 특이도 0.9047, F1 0.8484, 일치도 0.8828였다. 규칙엔진은 무라벨 사례 237건을 3라운드 맹검 판정하고 라벨을 SHA-256으로 잠근 뒤에야 예측을 연결하는 절차로 평가했다. released 규칙 15종 210건에서 AI 참조표준 대비 특이도 1.0000, 정밀도 1.0000, 민감도 0.5702, F1 0.7263였고 위양성 0건, 위음성 49건이었다.

규칙 16개 전부에 초록 문장 단위 locator 를 가진 문헌 근거를 연결했다(링크 20건, 고유 논문 19편). 허가원문과 어긋나는 4건은 지우지 않고 conflict 로 보존했다. 핵심어: 일반의약품, 식약처 허가원문, 제품명 기반 조회, PubMed, AI 문헌 선별, AI 참조표준, 맹검 독립평가

1. 서론

1.1 제품명으로 시작하는 안전성 질문

사람은 약을 성분명보다 제품명으로 기억한다. 하지만 같은 성분이 여러 감기약과 해열진통제에 들어가면 제품명만 보고 중복을 알아차리기 어렵다. 이 연구는 제품명을 입력점으로 삼고, 제품에서 성분으로, 성분에서 허가된 용량과 주의사항으로 거슬러 올라가는 구조를 택했다.

1.2 사실과 근거를 섞지 않는 이유

‘이 조합이 허가된 1일 최대량을 넘는다’는 말은 허가원문과 산술로 확인하는 사실 주장이다. 반면 ‘과량 복용이 간 손상과 연관된다’는 말은 문헌이 뒷받침하는 근거 주장이다. 이 연구는 두 문장을 한 권한 체계로 합치지 않는다. 허가원문은 판정을 내리고, PubMed 문헌은 판정의 배경을 설명한다.

1.3 연구 질문

첫째, 식약처 허가원문만으로 제품명 기반 위험 신호 판정을 구성할 수 있는가. 둘째, AI가 사람의 개입 없이 문헌 질문을 설계하고 코퍼스 전체를 선별할 수 있는가. 셋째, 그렇게 만든 규칙엔진의 판정이 독립적으로 구성한 참조 표준과 얼마나 일치하는가. 넷째, 일치하지 않는 지점은 무엇 때문인가.

2. 연구 방법

2.1 두 층 구조

이 연구의 근거는 두 층으로 나뉜다. 결정층은 식약처 허가원문이며 제품, 성분, 함량, 복용 조건, 규칙 판정을 확정한다. 설명층은 PubMed 문헌이며 판정의 배경을 설명하지만 판정을 바꾸지 못한다. 두 층은 별도 파일과 별도 컬럼에 저장하고, 문헌 근거에는 규칙을 배포시킬 권한을 주지 않는다.

식약처 의약품상세정보의 제품·원료약품·용법용량·사용상의주의사항을 구조화했다. 분석 집합은 제품 13개와 고유 성분 28개다. 계산에 사용하는 제품-성분 연결은 47개이며 복용 조건은 32개다. released 규칙은 15개, 전체 규칙은 16개다. 복용 조건 개수와 released 규칙 개수는 서로 다른 상태이므로 합치지 않는다.

2.2 AI 자율 PICOS와 PubMed 검색

AI에는 성분 28개, 규칙 16개의 유형과 범위, PubMed 단일 자료원이라는 제약만 제공했다. 이전 영양성분 검색 식이나 결과 수치는 제공하지 않았다. AI는 아세트아미노펜, NSAID, 감기·알레르기 복합성분, 소화제 복합성분, 외용 진통성분의 5개 질문으로 묶었다. 각 질문에는 대상, 노출, 비교, 결과, 연구설계와 MeSH·제목/초록 검색어를 기록했다. 질문 설계 프롬프트는 SHA-256 2ea152bb42f8b472... 로 고정했다.

항목	값	해석
아세트아미노펜 용량·간격·간질 환·음주 관련 위해	2,709	OTC-LIT-Q01-ACETAMINOPHEN
이부프로펜·덱시부프로펜·나프록센의 중복과 주요 위해	683	OTC-LIT-Q02-NSAID

감기·알레르기 복합성분의 진정·운전·혈압·병용 위해	1,533	OTC-LIT-Q03-COLD-ALLERGY
소화효소·담즙산·가스제거 성분 복합 사용의 안전성	104	OTC-LIT-Q04-DIGESTIVE
살리실산메틸·멘톨·캄파 등 외용 복합성분의 위해	713	OTC-LIT-Q05-TOPICAL

2.3 원시 응답과 코퍼스 계보

NCBI E-utilities는 API 키 없이 초당 세 번 이하로 호출했다. ESearch로 질문별 건수를 먼저 확인했고, 전체 상한을 넘긴 첫 검색은 EFetch 전에 중단했다. 좁힌 검색식으로 다시 실행한 뒤 query.txt, ESearch-EFetch XML, 응답 메타데이터와 SHA-256을 질문별 실행 폴더에 저장했다.

2.4 문헌 선별

선별 판정은 에이전트가 배치 카드를 직접 읽고 직접 기록했다(agent_direct). 지역 언어모델을 띄우지 않았고 외부 LLM API를 호출하지 않았으며 하위 에이전트에 위임하지 않았다. 라벨은 retain, deprioritize, uncertain 세 가지다. 초록이 없으면 title_only 로 구분하고 신뢰도 상한을 low 로 제한했다. 배치는 115개이고 전체 5,724행이 정확히 한 번씩 배치에 들어갔다. 판정은 append-only JSONL 체크포인트로 기록했으며 선별 프롬프트는 SHA-256 58186692d7cd2241... 로 실행 중 고정했다.

2.5 AI 참조표준

선별 결과의 재현도를 재기 위해 선별과 다른 프롬프트로 독립 참조표준을 만들었다. 근거 형태(초록 보유 여부) × 선별 판정의 6개 층에서 층별 최소 배정을 둔 뒤 총 300건을 뽑았고, 모든 지표에 층 가중치를 적용했다. 참조표준은 주제 적합성을 통째로 묻지 않고 P-I-C-O-S 다섯 요소를 따로 판정한 뒤 도구가 코드 규칙으로 종합 라벨을 도출한다. 카드에는 선별 판정·신뢰도·이유 코드를 제거하고 라운드별 별칭만 노출했으며 참조표준 프롬프트는 SHA-256 a163cf06e85f6979... 로 고정했다.

2.6 규칙엔진 AI 맹검 독립평가

실제 허가 데이터에서 정답 라벨과 엔진 예측이 없는 사례 237건을 만들었다. 사례 카드에는 제품명, 성분과 함량, 복용량, 정규화된 허가 상한, 식약처 허가원문 발췌(용법·용량과 사용상의 주의)와 사용자 조건만 넣고 규칙 ID·심각도·바인딩 표는 넣지 않았다. 라운드별 무작위 순서로 3회 판정한 뒤 다수결 라벨을 SHA-256으로 잠갔고, 잠금 해시를 검증한 다음에야 배포 규칙 15종만으로 엔진 예측을 기록했다. 지표 계산 단계는 잠금 시각이 예측 시각보다 앞선다는 것을 다시 확인한 뒤에만 실행된다.

2.7 문헌 근거 연결

retain 판정을 받은 문헌만 규칙에 연결했다. 연결 단위는 규칙 1건 × 논문 1편이며 각 연결은 초록의 문장 인덱스와 그 문장의 원문 인용을 함께 저장한다. 빌드할 때마다 코퍼스의 초록에서 해당 인덱스 문장을 다시 뽑아 저장된 인용문과 글자 단위로 대조하고, 어긋나면 빌드를 실패시킨다. 허가원문과 문헌이 다른 방향을 가리키면 어느 한 쪽을 지우지 않고 conflict 로 보존한다.

3. 결과

3.1 허가원문 결정충

항목	값	해석
분석 제품	13개	제품명 기반 입력 집합
고유 성분	28개	분석 제품에서 확인
제품-성분 연결	47개	계산용 선택 연결
복용 조건	32개	허가원문 검증 완료, 약사 재검토 별도
released 규칙	15개	전체 16개 중 source-locator 완비

3.2 문헌 검색충과 선별

항목	값	해석
AI PICOS 질문	5개	성분 28개와 규칙 16개 유형을 포괄
질문별 hit 합계	5,742건	질문 사이 중복 포함
고유 PMID	5,724개	중복 제거 뒤 코퍼스
초록 보유	5,424개	제목과 초록으로 선별
제목만 보유	300개	title_only, confidence=low 상한
선별 완료	5,724행	커버리지 1.0, 누락·중복 0
retain	2,240건	직접 근거 후보
deprioritize	3,423건	질문 직접성이 낮음
uncertain	61건	초록만으로 확정 어려움

3.3 선별기의 AI 참조표준 대비 재현도

항목	값	해석
총화 표본	300건	6개 층, 층 가중치 적용
채점 대상	255건	참조표준 uncertain 45건 제외
AI 참조표준 대비 민감도	0.8482	참조표준 retain 을 선별이 retain 으로 본 비율
AI 참조표준 대비 특이도	0.9047	참조표준 deprioritize 를 선별이 걸러낸 비율
AI 참조표준 대비 정밀도	0.8487	선별 retain 중 참조표준도 retain 인 비율
AI 참조표준 대비 F1	0.8484	민감도와 정밀도의 조화평균
AI 참조표준 대비 일치도	0.8828	가중 일치 비율
보정 유병률	0.3932	Rogan-Gladen 보정

보정 유병률을 코퍼스 전체에 적용하면 실제 retain 문헌은 약 2,251건으로 추정되며 95% 신뢰구간은 0.3519–0.4355이다. 라운드 3회의 평균 일치도는 1.0000였다. 이 값은 같은 평가자가 같은 명시적 규칙을 재적용한 결과이므로 판정 안정성이지만 서로 다른 평가자 간 신뢰도가 아니다.

3.4 규칙엔진의 AI 참조표준 대비 성능

항목	값	해석
무라벨 사례	237건	정답·예측 없이 생성
채점 대상	210건	uncertain 14건·맹검 훼손 2건 제외
AI 참조표준 대비 특이도	1.0000	위양성 0건
AI 참조표준 대비 정밀도	1.0000	엔진 경고 중 참조표준도 경고인 비율
AI 참조표준 대비 민감도	0.5702	위음성 49건
AI 참조표준 대비 F1	0.7263	민감도와 정밀도의 조화평균
AI 참조표준 대비 일치도	0.7667	전체 일치 비율

민감도의 95% 신뢰구간은 0.4785–0.6573, 특이도의 95% 신뢰구간은 0.9615–1.0000이다. 라운드 3회의 평균 일치도는 1.0000이고 3-way 불일치는 0건이었다. 참조 라벨 잠금 파일의 SHA-256은 bbf6d28c9cd306d6... 이며 예측 기록은 이 해시를 검증한 뒤에 생성됐다.

3.5 위음성이 몰린 지점

항목	값	해석
pregnancy_lactation	9건	규칙이 묶이지 않은 제품에서 허가원문이 같은 주의를 적음
sedative_medication	7건	규칙이 묶이지 않은 제품에서 허가원문이 같은 주의를 적음
anticoagulant_antiplaetlet	6건	규칙이 묶이지 않은 제품에서 허가원문이 같은 주의를 적음
gi_bleeding_ulcer	6건	규칙이 묶이지 않은 제품에서 허가원문이 같은 주의를 적음
renal_disease	6건	규칙이 묶이지 않은 제품에서 허가원문이 같은 주의를 적음
alcohol	5건	규칙이 묶이지 않은 제품에서 허가원문이 같은 주의를 적음
hepatic_disease	5건	규칙이 묶이지 않은 제품에서 허가원문이 같은 주의를 적음
sedation_driving	5건	규칙이 묶이지 않은 제품에서 허가원문이 같은 주의를 적음

위양성은 0건으로 엔진이 허가 근거 없이 경고하는 경우는 관찰되지 않았다. 반면 위음성 49건은 8개 규칙 유형에 몰려 있고, 모두 규칙이 대표 제품 하나에만 묶여 있어 같은 주의가 적힌 다른 제품에서 발동하지 않는 경우였다. 이는 판정 논리의 오류가 아니라 규칙 바인딩 범위의 공백이다.

draft 규칙 maximum_duration 은 draft 상태라 엔진이 발동하지 않는다. 동시에 참조표준도 해당 14건을 전부 uncertain 으로 판정했다. 대상 제품의 허가원문이 연속 복용 기간을 정성적으로만 적고 일수 기준을 주지 않기 때문이며, 이 규칙이 배포되지 못하는 이유가 참조표준 쪽에서 독립적으로 확인된다.

3.6 문헌 근거 연결

항목	값	해석
문헌이 연결된 규칙	16/16개	모든 규칙이 최소 1건
연결 수	20건	규칙 1건 × 논문 1편
고유 논문	19편	retain 판정 문헌만
보존한 충돌	4건	허가원문과 어긋나지만 지우지 않음
문헌이 연결된 제품	8/13개	제품 → 성분 → 문헌 축

4. 고찰

4.1 이층 구조가 주는 이점

문헌이 허가 판정을 덮어쓰지 않으므로 사실의 출처가 흐려지지 않는다. 사용자는 제품명으로 위험 신호를 찾고, 판정 근거로 허가원문 locator를 확인하며, 별도 참고 문헌에서 위해 연관성의 배경을 읽을 수 있다. 문헌과 허가 사항이 충돌해도 한쪽을 지우지 않고 충돌로 남길 수 있다.

4.2 특이도 1.0과 낮은 민감도의 비대칭

규칙엔진은 위양성 0건, 즉 허가 근거 없이 경고하는 경우가 없었다. 이는 규칙이 허가원문에 묶여 있고 locator 없이는 배포되지 않는 설계의 직접적 결과다. 반대로 위음성 49건은 규칙이 대표 제품 하나에만 묶여 있기 때문에 생긴다. 예를 들어 임신·수유 주의는 이부프로펜에만 묶여 있지만 나프록센과 텍시부프로펜의 허가원문에도 같은 주의가 적혀 있다. 따라서 다음 개선은 판정 논리를 바꾸는 것이 아니라 이미 허가원문에 있는 주의를 규칙 바인딩으로 옮기는 작업이다.

4.3 AI 참조표준이 설계 의도를 뒤집은 사례

사례 생성기는 발동 예상과 미발동 예상을 같은 수로 설계했지만, 참조표준이 허가원문을 읽고 판정한 결과 일부가 뒤집혔다. 예를 들어 2세대 항히스타민 제제의 허가원문에는 과량의 알코올과 함께 투여하지 말라는 문장이 있어 음주 노출이 성립했다. 설계 의도를 정답으로 삼지 않고 허가원문을 따랐다. 참조표준을 설계에 맞추는 순간 독립성이 사라지기 때문이다.

5. 한계

첫째, 이 논문의 모든 성능 수치는 AI 참조표준 대비 재현도이며 절대적 진실 대비 정확도가 아니다. 사람 판정은 0건이고 사람 블라인드 독립평가는 수행되지 않았다.

둘째, 문헌 분류기와 참조표준을 같은 에이전트가 수행했으므로 독립성이 부분적이다. 무라벨 사례, 별칭 카드, 라운드별 무작위 순서, 잠금 후 예측 연결이라는 절차적 맹검은 갖췄지만 평가자 독립성은 외부 사람 평가와 동등하지 않다. 라운드 간 일치도가 높게 나온 것도 같은 평가자가 같은 규칙을 재적용한 결과이며 평가자 간 신뢰도로 읽으면 안 된다.

셋째, 자료원은 PubMed 하나다. Embase 등 다른 데이터베이스를 사용하지 않았으므로 코퍼스가 특정 색인 관행에 치우쳤을 수 있다.

넷째, 판매량 자료가 없다. 분석 제품 13개는 대표 일반의약품 후보이며 판매 순위 집합이 아니다. 대표성을 주장하지 않는다.

다섯째, 복용 조건 32개는 허가원문 검증까지만 완료됐고 별도 약사 재검토를 거치지 않았다. 이 개수는 released 규칙 15개와 다른 상태이며 합쳐서 읽으면 안 된다.

여섯째, 규칙엔진 평가에서 참조표준이 판정하지 못한 14건과 사례 준비 중 라벨이 노출된 2건은 1차 지표에서 제외했다. 제외 사유와 건수를 산출물에 함께 기록했다.

6. 결론

이 연구는 식약처 허가원문을 결정층으로 유지하면서 AI가 설계한 PubMed 문헌 근거층을 별도로 만들었다. PICOS 5개와 고유 PMID 5,724개 코퍼스는 재현 가능한 원시 응답과 해시를 가지며, 코퍼스 전체를 선별해 커버리지 1.0을 달성했다.

규칙엔진은 AI 참조표준 대비 특이도 1.0000, 정밀도 1.0000로 허가 근거 없이 경고하지 않는다는 성질을 지켰고, 민감도 0.5702는 규칙 바인딩 범위의 공백에서 비롯됐다. 규칙 16개 전부에 문장 단위 locator 를 가진 문헌 근거를 연결했고 총돌 4건을 보존했다.

상태 플래그는 complete=true, independent_blinding_ai=true, performance_claim_allowed=true, independent_blinding=false, release_ready=false다. 성능 주장은 AI 참조표준 대비라는 사실과 평가자가 사람이 아니라는 사실을 항상 함께 적는 조건에서만 허용된다. 임상 배포 승인 절차는 이 연구의 범위 밖이다.

참고 자료

1. 식품의약품안전처 의약품안전나라. 의약품상세정보 및 허가 원문. 연구 원시자료의 source_id와 locator에 기록.
2. National Center for Biotechnology Information. Entrez Programming Utilities Help.
<https://www.ncbi.nlm.nih.gov/books/NBK25501/>
3. research_v3/protocol/protocol-v4.0-full-ai.md.
4. research_v3/otc/literature/picos/picos_definition.json.
5. research_v3/otc/literature/screening/screening_manifest.json.
6. research_v3/measurement/screener_vs_ai_reference.json. 선별기의 AI 참조표준 대비 재현도.
7. research_v3/otc/validation/ai_independent_evaluation.json. 규칙엔진 AI 맹검 독립평가.
8. research_v3/otc/rules/literature_link_manifest.json. 규칙별 문헌 근거 연결과 보존한 총돌.
9. research_v3/otc/audit/completion_audit.json. 상태 플래그와 근거 파일 경로.
10. research_v3/otc/metrics_manifest.json.

부록 A. 재현성 식별자

항목	값	해석
PICOS 프롬프트 SHA-256	2ea152bb42f8b47 2406883a470e14 9d11b9b9fa6b58d d9908f29492895 9ac414	AI 질문 설계 프롬프트
선별 프롬프트 SHA-256	58186692d7cd22 41b4342578babe 6d87615f762bafb cda2445d20f9633 0c3a60	고정된 P2 선별 프롬프트
참조표준 프롬프트 SHA-256	a163cf06e85f697 9ae29af3f15e21b2 5b13f304812d986 877894abd9d906 8387	P3-A 요소별 채점 프롬프트
코퍼스 입력 SHA-256	5b0bcc9f47a98a4 caa7a24599962ac 5d5bcc372fd8edb 29bfd67a4b1af787 86c	evidence_map.csv
참조 라벨 잠금 SHA-256	bbf6d28c9cd306d 642c83a9992664 3839f7f1bc53056 b88bfd1f40565f37 9c03	P3-B 잠금 후 예측 연결
판정 주체	agent_direct	사람 판정 0건